

## 第一章 快速参考

### 第1条 关键配置速查表

场景	芯片数	推荐配置	性能预期	注意事项
Decode 标准部署	128	TP4+DP32+EP128, B10	TPS/Chip=108	性价比最佳★
Decode 高吞吐	256	TP4+DP64+EP256, B12	TPS/Chip=138 (+28%)	总吞吐翻倍
Prefill	16-32	TP4+SP4+EP16/32, B4-8	FTL=2.2-2.5s	单芯效率 400%+
小规模部署	64	❌ 不推荐	TPS/Chip=40 (-63%)	建议用 128 芯

#### 1) 核心策略:

- a) ☒ TB0: 仅高带宽芯片+大Batch场景 (SG2260E不需要)
- b) ☒ MOE\_TP: 固定为1 (仅做EP)
- c) ☒ MLA\_TP: 优先选择4 (平衡通信与计算)
- d) ☒ EP: 越大越好 (256 > 128 > 64)
- e) ☒ Batch: 满足SL0前提下越大越好

### 第2条 常见问题FAQ

- 1) Q1: 为什么TPS per Chip随Batch增大而增大, 但有SL0约束?
  - a) Batch越大 → 计算密集度高 → TPS per Chip高
  - b) 但Batch越大 → TPOT越长 → TPS per Batch低
  - c) 需要平衡用户体验 (TPS per Batch) 和芯片利用率 (TPS per Chip)
- 2) Q2: 为什么MFU只有12%?
  - a) DeepSeek-V3是访存密集型模型 (大量权重和KV Cache访问)
  - b) DRAM带宽273GB/s相对计算能力128T是瓶颈
  - c) 这是正常现象, 不代表芯片性能差
- 3) Q3: 如何选择网络拓扑?
  - a) 如果TP Group间能直连 (A112A11): 设置`inter\_bw=64GB/s`
  - b) 如果TP Group间只能PCIe: 设置`inter\_bw=16GB/s`
  - c) 性能差异约10-15%
- 4) Q4: 数学建模结果可信吗?
  - a) **相对比较可信**: 配置排序准确 (TP4优于TP2/TP8等)

- b) **绝对值有误差**: 实际TPS可能有5-15%的偏差
  - c) **趋势分析准确**: EP越大性能越好等结论可靠
  - d) **建议**: 最终方案在实际硬件上验证
- 5) Q5: 如何处理Prefill和Decode节点的吞吐量不匹配?
- a) 通过调整PD节点数量比例实现匹配
  - b) 例如:  $\text{Prefill节点数} / \text{Decode节点数} = \text{Decode吞吐} / \text{Prefill吞吐}$
  - c) 暂不考虑PD节点之间的KV Cache传输

