

第一章 优化目标与约束条件

第1条 问题定义

核心问题：给定硬件配置和模型架构，如何选择最优的并行策略和 Batch Size，使得在满足服务质量（SLO）的前提下，单芯片吞吐量最大化。

评估对象：目前以 DeepSeek-V3 (671B) 为基准模型进行评估

第2条 优化目标

1) 主要优化目标

$$\max \text{TPS}_{\text{per chip}}$$

在满足所有约束条件的前提下，最大化单芯片的吞吐量(TPS per Chip)。

2) 分阶段优化目标

Prefill 阶段：

$$\begin{cases} \max & \text{Throughput}_{\text{per chip}} \\ \text{s. t.} & \text{FTL} \leq T_{\text{FTL}}^{\max} \end{cases}$$

在首Token延迟（FTL）满足SLO的前提下，最大化单芯片的Prefill吞吐量

Decode 阶段：

$$\begin{cases} \max & \text{TPS}_{\text{per chip}} \\ \text{s. t.} & \text{TPS}_{\text{per batch}} \geq T_{\text{TPS}}^{\min} \end{cases}$$

在单Batch吞吐量（TPS per Batch）满足SLO的前提下，最大化单芯片的总吞吐量

第3条 约束条件

1) 性能约束（SLO）

a) Decode阶段的**单Batch吞吐量约束**（用户体验）：

$$\text{TPS}_{\text{per batch}} = \frac{1}{\text{DecodeTime (s)}} \geq 10$$

即：

$$\text{DecodeTime} \leq 100 \text{ ms}$$

b) Prefill阶段的首Token延迟约束：公式表示：

$$\text{FTL} = T_{\text{prefill}} \leq T_{\text{FTL}}^{\max}$$

输入长度	FTL 上限
4K tokens	≤ 3s
8K tokens	≤ 5s

2) 硬件约束

a) DRAM容量约束

每个芯片的显存占用不能超过芯片DRAM容量：

$$\text{DRAM}_{\text{required}} \leq \text{DRAM}_{\text{chip}}$$

其中显存需求包括：

$$\text{DRAM}_{\text{required}} = \frac{\text{Weight}_{\text{MLA}}}{\text{MLA}_{\text{TP}} \times \text{MLA}_{\text{DP}}} + \frac{\text{Weight}_{\text{MoE}}}{\text{MOE}_{\text{TP}} \times \text{MOE}_{\text{EP}}} + \frac{\text{KVCache} \times \text{Batch}}{\text{MLA}_{\text{TP}} \times \text{MLA}_{\text{DP}}}$$

参数说明：

$\text{Weight}_{\text{MLA}}$ ：MLA部分权重大小

$\text{Weight}_{\text{MoE}}$ ：MoE部分权重大小

KVCache：单个请求的KV Cache大小

Batch：总Batch大小

b) 芯片数量约束（并行度一致性）

$$\text{MLA}_{\text{TP}} \times \text{MLA}_{\text{DP}} = \text{MOE}_{\text{TP}} \times \text{MOE}_{\text{EP}} = N_{\text{chips}}$$

说明：MLA和MoE部分可以采用不同的并行策略，但总芯片数必须一致。

c) 网络拓扑约束

C2C带宽（Chip-to-Chip）：影响TP通信性能

All-to-All带宽：影响EP通信性能

并行度需与拓扑匹配：如8卡机器不能设置TP=16

第4条 可优化变量

变量	可选值	说明	约束
Batch	1, 2, 4, 8, 10, 12, 16, 32, 64, 128, 256, 512, 1024, 1280	总 Batch 大小	$\text{Batch} \geq 1$
MLA_TP	1, 2, 4, 8, 16, 32	MLA 的张量并行度	2 的幂次
MLA_DP	1, 2, 4, 8, 16, 32, 64	MLA 的数据并行度	$\text{MLA}_{\text{TP}} \times \text{MLA}_{\text{DP}} = N_{\text{chips}}$
MOE_TP	1, 2, 4, 8	MoE 的张量并行度	一般 ≤ 8
MOE_EP	16, 32, 64, 128, 256	专家并行度	$\text{MOE}_{\text{TP}} \times \text{MOE}_{\text{EP}} = N_{\text{chips}}$
SP	1, 2, 4	序列并行度	$\text{SP} \mid \text{MLA}_{\text{TP}}$

1) 变量说明

a) Tensor Parallelism (TP)

作用：将模型权重按列/行切分到多个芯片

收益：降低单芯片显存占用和计算量

代价：增加AllReduce通信开销

建议: $MLA_TP = 2-8$, $MOE_TP = 1-4$

b) Data Parallelism (DP)

作用: 不同芯片处理不同的数据样本

收益: 提升总吞吐量, 无通信开销

代价: 不降低单样本延迟

建议: 在满足SLO后, 优先增大DP

c) Expert Parallelism (EP)

作用: 将MoE的专家分配到不同芯片

收益: 降低单芯片显存占用

代价: 增加All-to-All通信 (Dispatch/Combine)

建议: $EP = 16-256$, 取决于专家数量和网络带宽

d) Sequence Parallelism (SP)

作用: 将序列按长度切分到多个芯片

收益: 降低Prefill阶段的激活值显存占用

代价: 增加AllGather/ReduceScatter通信

建议: 主要用于长序列Prefill (如8K+)

第5条 评估流程

1. 遍历所有可行的配置组合

- └─ 选择 (Batch, MLA_TP, MLA_DP, MOE_TP, MOE_EP, SP)
- └─ 检查是否满足芯片数量约束

2. 计算性能指标

- └─ 显存占用: $DRAM_required$
- └─ 计算时间: T_comp
- └─ 访存时间: T_mem
- └─ 通信时间: T_comm
- └─ 总时间: $T_total = \max(T_comp, T_mem) + T_comm$

3. 检查约束条件

- └─ $DRAM_required \leq DRAM_chip$?
- └─ $TPS_per_batch \geq 10$? (Decode)
- └─ $FTL \leq T_max$? (Prefill)

4. 计算优化目标

- └─ $TPS_per_chip = Batch / T_decode$

5. 选择最优方案

- └─ $\max TPS_per_chip$ (满足所有约束)

第6条 评估范围

- 1) 模型:
 - a) ☒ DeepSeek-V3 (671B, MoE)
 - b) ☐ Dense模型 (暂不考虑, 后续扩展)
- 2) 阶段:
 - a) ☒ Prefill阶段 (4K/8K Input)
 - b) ☒ Decode阶段 (4K Input + 生成)
- 3) 优化技术:
 - a) ☒ TP/DP/EP/SP 并行策略
 - b) ☒ Batch Size 优化
 - c) ☐ TBO (Two-Batch Overlap, 可选)
 - d) ☒ Continuous Batching (不考虑动态调度)
 - e) ☒ Speculative Decoding (不考虑推测解码)

第7条 建模假设

- 1) PD节点独立:
 - a) 不考虑Prefill与Decode节点的吞吐量匹配
 - b) 实际部署可通过调整PD节点数量比例实现
- 2) KV Cache传输:
 - a) 不考虑PD节点之间的KV Cache传输或重算
 - b) 假设无KV Cache专属硬件资源
- 3) 负载均衡:
 - a) 假设MoE路由完全均衡 (理想情况)
 - b) 不考虑专家负载不均导致的性能下降
- 4) 网络稳定:
 - a) 假设网络带宽恒定, 无拥塞
 - b) 不考虑网络抖动或故障

第8条 输出最优方案

- 1) Decode阶段最优方案:

参数	最优值	说明
----	-----	----

Batch	?	使 TPS per Chip 最大
MLA_TP	?	平衡通信与计算
MLA_DP	?	满足芯片数约束
MOE_TP	?	通常为 1 或 2
MOE_EP	?	根据专家数和带宽
TPS per Batch	≥ 10	满足 SLO
TPS per Chip	最大值	优化目标
DRAM per Chip	$\leq \text{DRAM_chip}$	满足硬件约束

2) Prefill阶段最优方案:

参数	最优值	说明
MLA_TP	?	降低计算时间
SP	?	处理长序列
FTL	$\leq 3s (4K) / \leq 5s (8K)$	满足 SLO
Throughput per Chip	最大值	优化目标

3) 做出性能分析瓶颈分析:

Decode阶段: 计算受限 vs 访存受限 vs 通信受限

Prefill阶段: 计算受限 vs 通信受限敏感性分析: 成本效益:

- Batch Size对吞吐量和延迟的影响
- TP对通信开销的影响
- EP对All-to-All通信的影响
- 单芯片TPS (成本效率)
- 总TPS (集群吞吐)
- 性价比: $\text{TPS} / (\text{芯片数} \times \text{芯片单价})$

