

第一章 扩展案例分析

第1条 案例A：256芯方案（高吞吐场景）





1) 配置：

```
configs_256 = generate_configs(  
    num_chips=256,  
    tp_candidates=[4],  
    batch_candidates=[10, 12, 16]  
)
```

2) 最优方案：

参数	256 芯	128 芯	提升
配置	TP4+DP64+EP256, B12	TP4+DP32+EP128, B10	EP 翻倍
TPS/Chip	138	108	+27.8%
总吞吐量	35,328TPS	13,824 TPS	+155.6%
TPS/Batch	12.6	10.3	+22.3%
最佳 Batch	12	10	+2



3) 关键发现：

- a)  EP256显著优于EP128：MoE通信减少，性能提升28%
- b)  支持更大Batch：Batch=12仍满足TPS/Batch≥10
- c)  总吞吐量翻倍：从13.8K提升到35.3K TPS
- d)  单芯效率也提升：不仅总量大，单芯效率也提升

4) 适用场景：超大规模推理服务（日请求量千万级）

第2条 案例B：64芯方案（不推荐）




1) 配置扫描结果：

Batch	MLA_T P	TPS/Batch	TPS/Chip	DRAM(GB)	满足 SLO?
4	4	10.0	39.8	14.8	 刚好满足
6	4	9.3	55.5	14.8	 不满足
8	4	8.6	69.1	14.8	 不满足

2) 问题分析：

- a) 仅Batch=4能满足SLO，但TPS/Chip仅39.8（128芯的37%）
- b) Batch做不大，无法充分利用硬件
- c) EP=64相比EP=128，MoE通信开销显著增加

3) 建议：





- a)  不使用64芯作为单一Decode节点
- b)  部署2个独立32芯实例
- c)  或与其他64芯组合成128芯

第3条 案例C: 16芯Prefill方案

1) 配置与结果:

Batch	MLA_TP	MLA_DP	MOE_EP	TPS/Chip	FTL(ms)	满足 FTL≤3s	评价
-----	-----	-----	-----	-----	-----	-----	-----
4	4	4	16	462	2213		最优★
4	4	4	8	443	2621		次优
5	16	1	16	329	3896		不满足FTL
8	2	8	16	407	2517		可选

2) Prefill方案分析:

- a)  **最优配置:** TP4+SP4+EP16, Batch4
- b)  **性能:** FTL=2.2s < 3s, 单芯吞吐462 TPS/Chip
- c)  **总吞吐量:** 7,392 TPS (16芯)
- d)  **关键特点:**

Prefill适合较小Batch (4-8), 因为Input长度大
 TP16虽然通信少, 但单芯计算效率低, FTL反而更长
 SP (Sequence Parallel) 在Prefill阶段很有效

