

第一章 模型相关参数定义

第1条 Benchmark表达方式

在部署方案优化问题中，benchmark 的评估需要明确以下参数：

模型 (Model)：由产品方确定，包括模型架构和参数量 (Size)

输入输出长度 (SeqLen)：通常由产品方确定，包括输入序列长度 (Input SeqLen) 和输出序列长度 (Output SeqLen)

量化方式 (Dtype)：通常由产品方确定，但可以协助确定最优量化方案，用 W[x]A[y] 表示 (例如 W4A16 表示 weight 为 4bit, activation 为 16bit)

Batch Size (BS)：主要评估变量，根据前面确定的模型、参数量、输入输出长度、量化方式等参数，通过数学建模分析确定最优的 Batch Size

Benchmark 命名规则：

参考 LLM 和 CV 模型的性能指标表达方式，benchmark 命名遵循以下规则：

- 1) **LLM 模型 TPS**：`TPS[xxx]-[Model]-[Size]-S[SeqLen]-O[SeqLen]-W[x]A[y]-B[BS]`
 - a) 示例：`TPS001-Llama2-70B-S4K-O1-W4A16-B16`
 - b) 说明：Llama2-70B模型使用W4A16精度，在BS为16，输入SeqLen为4K，输出SeqLen为1时的TPS
- 2) **LLM模型FTL**：`FTL[xxx]-[Model]-[Size]-S[SeqLen]-W[x]A[y]-B[BS]`
 - a) 示例：`FTL001-Llama2-70B-S4K-W4A16-B1`
 - b) 说明：Llama2-70B模型使用W4A16精度，在BS为1，输入SeqLen为4K时的FTL
- 3) **CV模型FPS**：`FPS[xxx]-[Model]-[Version]-R[Resolution]-W[x]A[y]-B[BS]`
 - a) 示例：`FPS001-Resnet50-V2-R224x224-W8A8-B4`
 - b) 说明：Resnet50-V2模型权重和激活都使用8bit精度，在BS为4，分辨率是224x224时的FPS

评估重点：

在部署方案优化中，我们主要根据产品方确定的模型、参数量、输入输出长度、量化方式等固定参数，通过数学建模分析来评估和优化 **Batch Size**，以满足 SLO 约束的前提下实现 TPS per Chip 的最大化。

第2条 DeepSeek-V3 配置解析

下面按功能块解释 DeepseekV3 配置，重点放在与 MoE (混合专家) 路由与负载相

关的参数，同时也覆盖与注意力、尺寸、量化等有关的关键项。以下参数均来自 [HuggingFace DeepSeek-V3 模型卡](#) 中的`config.json`文件。可以按相同方法从其他模型的 HuggingFace 页面（如 Llama、Qwen 等）获取对应的`config.json`，为其他大语言模型制定部署方案提供参数。

1) 模型结构与尺寸

- a) `hidden_size: 7168`
模型的主隐层维度（Transformer层的特征维度）。
- b) `intermediate_size: 18432`
非 MoE 的标准前馈（FFN）层的中间维度（通常对应第一个线性层的扩展维度）。
- c) `moe_intermediate_size: 2048`
MoE专家的FFN中间维度。说明专家的每个 FFN 比主干 FFN 要小很多，靠稀疏并行堆叠来提升总容量。
- d) `num_hidden_layers: 61`
Transformer层数。
- e) `num_attention_heads: 128, num_key_value_heads: 128`
注意力的总头数以及KV头数。KV与Q一致（无GQA缩减）。
- f) `qk_rope_head_dim: 128, qk_rope_head_dim: 64, v_head_dim: 128`
注意力中各分量的头维度：Q/K的非ROPE部分维度、ROPE部分维度，以及V的头维度。QK被拆分为 NOPE 与 ROPE 两段。
- g) `initializer_range: 0.02`
参数初始化范围（通常是正态/均匀的尺度）。
- h) `rms_norm_eps: 1e-06`
RMSNorm 的数值稳定性参数。
- i) `vocab_size: 129280, tie_word_embeddings: false`
词表大小；不共享输入/输出嵌入权重。

2) 注意力与位置编码

- a) `attention_bias: false`
注意力线性层是否使用bias。
- b) `attention_dropout: 0.0`
注意力dropout，设为0以提高吞吐（推理或大模型常见）。
- c) `rope_theta: 10000`
ROPE的基础角频参数。
- d) `rope_scaling: { type: "yarn", factor: 40, beta_fast: 32,`

`beta_slow: 1, mscale: 1.0, ... }`

使用 YaRN 风格的 ROPE扩展与缩放，以支持超长上下文。`factor=40` 表示对原始最大长度的扩展；`beta_fast/beta_slow` 是 YaRN 的双速缩放参数；`original_max_position_embeddings: 4096` 指原始设计长度；`max_position_embeddings: 163840` 为最终支持长度 ($4096 \times 40 \approx 163,840$)。

e) `max_position_embeddings: 163840`

最大位置长度，与上面一致，支持极长上下文。

3) MoE总体结构

a) `n_routed_experts: 256`

可被路由的稀疏专家数量（不含共享专家）。

b) `n_shared_experts: 1`

共享专家（dense expert），所有token都可以走它，相当于“保底”路径，常用于稳定训练和提升鲁棒性。

c) `moe_layer_freq: 1`

MoE层出现的频率。为1通常意味着每一层都是MoE（或每层的FFN部分是MoE版本），而不是每隔N层一个MoE。

d) `routed_scaling_factor: 2.5`

对经由专家路径的输出进行缩放的因子。一般用于匹配稀疏路由带来的统计幅度变化，防止MoE输出的方差与dense路径不一致。

4) MoE路由与选择策略（关键）

a) `num_experts_per_tok: 8`

每个token选择的专家数（Top-k）。这里是Top-8，相比常见Top-1/Top-2更大，能显著平滑负载，但计算与通信成本更高。

b) `topk_group: 4`

将专家分为若干组（group），先在组内或跨组做Top-k的策略。`topk_group=4` 表示把256专家分成4个组（每组64），路由可能先选组再选组内专家，用于降低搜索成本和改善并行通信模式。

c) `scoring_func: "sigmoid"`

路由打分函数。用sigmoid将路由logits压到(0,1)，与softmax不同，它不强制归一到总和为1的概率分布，常配合“`norm_topk_prob`”做归一化。

d) `norm_topk_prob: true`

对Top-k选择后的权重进行归一化（例如把选中专家的权重归一为和

为1)，保证融合时数值稳定。

e) `topk_method: "noaux_tc"`

路由方法标识：

f) `"noaux"` 通常表示不使用传统的负载均衡辅助损失 (auxiliary load-balancing loss)。

g) `"tc"` 很可能指 token capacity / topk capacity 的实现路径 (具体到DeepSeek V3的源码：通常代表基于容量/阈值的截断或按token计的capacity管理策略)。整体含义是使用一种不依赖aux loss，而是依靠容量和分组/排序的路由策略来实现负载控制。

h) `n_group: 8`

与 `topk_group` 不同的分组粒度参数。DeepSeek V3中通常有两个分组相关参数：一个用于通信/并行 (`n_group=8`，把专家或路由分在8个通信分区以优化带宽与布局)，另一个用于挑选 (`topk_group=4`)。二者共同决定路由的分区与选择路径。

i) `ep_size: 1`

`expert parallel size`。每设备上的专家并行数或专家分片数的配置。`ep_size=1` 表示没有跨设备的专家并行 (所有专家可能在同一设备视图或采用其它并行)，在实际分布式运行中这个参数通常与训练框架 (如Megatron/DeepSpeed) 结合使用。

5) MoE行为的其他辅助项

a) `first_k_dense_replace: 3`

训练或推理早期/前几层使用dense FFN替代MoE (或强制走共享专家)，以稳定路由与梯度。这有助于避免训练初期的“热门专家”极化问题。值为3表示前3层用dense。

b) `topk_method` 与 `capacity` 的关系

虽未直接给出 `capacity_factor`，但 `"noaux_tc"` 暗示采用基于容量的截断/重排策略，常见做法是每个专家有每步的token容量上限，超出则丢弃或转移到共享专家。这能在没有aux loss的情况下维持负载可控。

6) 并行与缓存

a) `use_cache: true`

推理时缓存KV以加速自回归生成。

b) `attention_bias: false`, `attention_dropout: 0.0`

这两项在推理友好配置中常见，减少额外开销。

7) LoRA相关（注意力权重低秩分解，特定于DeepSeek V3）

a) `q_lora_rank: 1536`

对Q投影采用LoRA的秩。

b) `kv_lora_rank: 512`

对K/V投影采用LoRA的秩。

这些用于降低参数/计算或更易微调，同时保留较强表达能力。

DeepSeek V3中Q/K/V有分头维度与ROPE/NOPE拆分，配合LoRA可以更灵活。

8) 量化与数值精度

a) `torch_dtype: "bfloat16"`

主计算精度为BF16。

b) `quant_method: "fp8", fmt: "e4m3"`

使用FP8 (E4M3格式) 进行权重或激活的量化以提升吞吐与减小显存。

c) `activation_scheme: "dynamic"`

动态激活量化策略（按批或按层动态调整尺度）。

d) `weight_block_size: [128, 128]`

权重量化的块大小（影响scale的粒度与吞吐）。

e) `scale_fmt: "ue8m0"`

量化scale的数据格式。

这套配置表明模型走混合精度：主算BF16，但某些权重/激活用FP8量化以进一步优化性能。

